

# 기초 통계 분석

# 1. 기초통계량

### 평균 (Mean)

- **정의:** 평균은 데이터 집합의 모든 값의 합을 데이터의 개수로 나눈 값이다. 이는 데이터의 중심 위치를 나타내며, 데이터 집합의 중앙값을 설명한다.

- **계산 방법**

예를 들어, 데이터 집합이  $\{x_1, x_2, \dots, x_n\}$  라면 평균  $\bar{x}$  는 다음과 같이 계산된다.

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

여기서  $n$ 은 데이터의 개수,  $x_i$ 는 각 데이터 값이다.

- **특징**

평균은 데이터의 모든 값을 고려하여 계산되므로, 극단값(이상치)의 영향을 많이 받는다.

# 중앙값 (Median)

- **정의:** 데이터 집합을 크기 순서대로 정렬했을 때 중앙에 위치한 값  
데이터가 홀수 개일 때는 정확히 중앙에 있는 값이고, 짝수 개일 때는 중앙에 있는 두 값의 평균이다.
- **계산 방법:**  
데이터를 크기 순서대로 정렬한 후, 데이터 개수가  $n$  인 경우:
  - 홀수 개일 때: 중앙값 = 정렬된 데이터의  $(n+1)/2$  번째 값
  - 짝수 개일 때: 중앙값 = 정렬된 데이터의  $n/2$  번째 값과  $n/2 + 1$  번째 값의 평균
- **특징:**  
중앙값은 극단값의 영향을 받지 않으므로, 데이터에 이상치가 포함된 경우에도 데이터의 중심을 잘 나타낸다.

### 최빈값 (Mode)

- **정의:** 최빈값은 데이터 집합에서 가장 자주 나타나는 값이다.  
데이터에 따라 하나 이상의 최빈값이 존재할 수 있다.
- **계산 방법:**  
각 값의 빈도를 계산하여, 빈도가 가장 높은 값을 최빈값으로 선택합니다.
- **특징:** 최빈값은 데이터의 분포를 이해하는 데 유용하며, 특히 명목형 데이터(순서를 매길 수 없는 데이터, 예를 들면, 성별, 종교, 색깔 등, <https://wikidocs.net/161040#nominal>)에서 자주 사용된다.

### 분산 (Variance)

- **정의:** 분산은 데이터가 평균에서 얼마나 떨어져 있는지를 나타내는 값으로, 데이터의 흩어짐 정도를 나타낸다. 이는 평균에서 각 데이터 값의 편차의 제곱의 평균으로 계산된다.

- **계산 방법:**

- 데이터 집합  $\{x_1, x_2, \dots, x_n\}$  에 대해 분산  $\sigma^2$ 는 다음과 같이 계산된다.

$$\sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

- **특징:** 분산은 단위가 원래 데이터의 단위의 제곱이므로, 데이터의 변동성을 직접적으로 비교하기에는 어려움이 있다.

### 표준편차 (Standard Deviation)

- **정의:** 표준편차는 분산의 제곱근으로, 데이터의 산포도를 나타내는 값이다. 이는 데이터가 평균에서 얼마나 떨어져 있는지를 직관적으로 이해할 수 있도록 해준다.

- **계산 방법:**

분산  $\sigma^2$  의 제곱근으로 계산된다.

$$\sigma = \sqrt{\sigma^2} = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}$$

- **특징:** 표준편차는 원래 데이터와 같은 단위를 가지므로, 데이터의 변동성을 이해하고 비교하는 데 유용하다.

## 1. 기초통계량

이와 같이 기초통계량은 데이터의 중심 경향과 변동성을 이해하는 데 중요한 지표들을 제공한다.

각 통계량의 계산 방법과 특징을 잘 이해하면, 데이터 분석의 기본기를 탄탄히 다질 수 있다.

## 2. 상관 관계 분석

## 2. 상관 관계 분석

### 상관관계란?

상관관계는 두 변수 간의 관계를 나타내는 개념으로, 한 변수의 변화가 다른 변수의 변화와 어떻게 관련되어 있는지를 보여줌. 상관관계는 양의 상관관계와 음의 상관관계로 구분되며, 이를 통해 변수 간의 관계를 정량적으로 파악할 수 있다.

• **양의 상관관계:** 한 변수가 증가할 때 다른 변수도 증가하는 경향을 보이는 관계를 의미함. 예를 들어, 공부 시간과 성적 사이에는 양의 상관관계가 존재할 수 있다.

• **음의 상관관계:** 한 변수가 증가할 때 다른 변수는 감소하는 경향을 보이는 관계를 의미함. 예를 들어, 스트레스 수준과 수면 시간 사이에는 음의 상관관계가 존재할 수 있다.

## 2. 상관 관계 분석

### 상관계수 (Correlation Coefficient)

상관계수는 두 변수 간의 상관관계의 정도를 나타내는 값으로, -1에서 1 사이의 값을 가짐. 상관계수가 1에 가까울수록 강한 양의 상관관계를, -1에 가까울수록 강한 음의 상관관계를 나타냄. 0에 가까울수록 상관관계가 없음을 의미한다.

• **피어슨 상관계수 (Pearson Correlation Coefficient):** 두 변수 간의 선형 관계를 측정함. 연속형 변수 간의 상관관계를 분석할 때 주로 사용하며, 다음과 같이 계산한다

$$r = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2 \sum (y_i - \bar{y})^2}}$$

• 여기서 r 값이 1에 가까울수록 강한 양의 상관관계, -1에 가까울수록 강한 음의 상관관계를 의미한다.

## 2. 상관 관계 분석

### 스피어만 상관계수 (Spearman Correlation Coefficient):

두 변수 간의 비선형 관계를 측정함. 순위형 변수 또는 비정규 분포를 가진 변수 간의 상관관계를 분석할 때 사용하며, 다음과 같이 계산한다

$$\rho = 1 - \frac{6 \sum d_i^2}{n(n^2 - 1)}$$

여기서  $d_i$ 는 각 관찰치의 순위 차이,  $n$ 은 데이터의 개수임. 스피어만 상관계수는 데이터가 순위형일 때나 비선형 관계가 있을 때 유용하다

### 상관관계 분석의 목적

상관관계 분석은 변수 간의 관계를 이해하고 예측 모델을 개발하는 데 중요한 역할을 한다.

예를 들어, 마케팅에서 광고비와 판매량 간의 상관관계를 분석하여 광고비 증가가 판매량에 미치는 영향을 파악할 수 있다.

또한, 금융 분야에서는 주식 간의 상관관계를 분석하여 포트폴리오를 최적화할 수 있다. 이를 통해 변수 간의 관계를 이해하고, 더 나은 의사결정을 내릴 수 있다.

### 상관관계와 인과관계의 차이

상관관계는 두 변수 간의 관계를 나타내지만, 인과관계를 증명하지는 못한다. 상관관계가 있다고 해서 한 변수가 다른 변수의 원인이라고 단정할 수 없다.

예를 들어, 아이스크림 판매량과 익사 사고 건수 간에 상관관계가 있을 수 있지만, 이는 여름철이라는 공통 요인이 원인일 가능성이 크다. 따라서, 상관관계를 인과관계로 해석할 때는 주의가 필요하다.

인과관계를 확인하려면 추가적인 실험이나 연구가 필요하다.

### 상관관계 분석의 한계

상관관계 분석은 변수 간의 관계를 파악하는 데 유용하지만, 몇 가지 한계가 있다.

첫째, 상관관계는 선형 관계만을 나타내므로 비선형 관계를 포착하지 못할 수 있다.

둘째, 이상치의 영향을 받을 수 있다.

마지막으로, 상관관계는 인과관계를 나타내지 않으므로, 변수 간의 원인과 결과를 분석하려면 추가적인 연구가 필요하다.

이러한 한계를 인지하고 분석을 진행해야 신뢰성 있는 결과를 도출할 수 있다.

## 2. 상관 관계 분석

### 상관관계 분석의 예시

#### 1. 광고비와 판매량

광고비와 판매량 간의 상관관계를 분석하여 광고비가 판매량에 미치는 영향을 파악할 수 있다. 이를 통해 마케팅 전략을 수립할 때 유용한 정보를 얻을 수 있다.

#### 2. 키와 체중

사람들의 키와 체중 간의 상관관계를 분석하여 키가 클수록 체중도 증가하는 경향이 있는지 확인할 수 있다. 이는 건강 및 체력 관리에 중요한 정보를 제공할 수 있다.

#### 3. 학습 시간과 성적

학생들의 학습 시간과 시험 성적 간의 상관관계를 분석하여 학습 시간이 길수록 성적이 높아지는지 확인할 수 있다. 이를 통해 효과적인 학습 전략을 개발할 수 있다.

### 요약

상관관계 분석은 다양한 분야에서 변수 간의 관계를 이해하고 예측하는데 중요한 도구로 사용된다. 상관계수를 통해 변수 간의 관계의 강도와 방향을 정량적으로 파악할 수 있으며, 이를 기반으로 다양한 의사결정에 활용할 수 있다.

### **3. 탐색적 데이터 분석(EDA)**

## 탐색적 데이터 분석(EDA - Exploratory Data Analysis)란?

탐색적 데이터 분석(EDA)은 데이터셋의 주요 특성을 요약하고 시각화하는 초기 분석 단계임. 이를 통해 데이터의 구조를 이해하고, 패턴을 발견하며, 가설을 수립하는 데 도움을 줄 수 있다. EDA는 데이터 분석 과정에서 중요한 첫 단계로, 데이터의 질을 평가하고 분석 방향을 설정하는 데 유용하다.

### 3. 탐색적 데이터 분석

## 데이터 시각화

데이터 시각화는 EDA의 핵심 요소로, 데이터를 시각적으로 표현하여 패턴, 이상치, 관계 등을 쉽게 파악할 수 있게 해준다. 주요 시각화 기법은 다음과 같다.

- **히스토그램 (Histogram)**: 데이터의 분포를 시각화하는 데 사용됨. 연속형 변수의 분포와 빈도수를 파악할 수 있다.
- **상자 그림 (Box Plot)**: 데이터의 중앙값, 사분위수, 이상치를 시각화하는 데 사용됨. 데이터의 분포와 변동성을 한눈에 확인할 수 있다.
- **산점도 (Scatter Plot)**: 두 변수 간의 관계를 시각화하는 데 사용됨. 변수 간의 상관관계를 파악할 수 있다.
- **막대 그래프 (Bar Chart)**: 범주형 데이터의 빈도를 시각화하는 데 사용됨. 각 범주의 빈도나 비율을 비교할 수 있다.
- **선 그래프 (Line Chart)**: 시간에 따른 데이터의 변화를 시각화하는 데 사용됨. 시간 시계열 데이터를 분석할 때 유용하다.

### 3. 탐색적 데이터 분석

#### 데이터 요약

데이터 요약은 데이터의 주요 특성을 요약하는 과정으로, 주요 통계량을 계산하여 데이터를 이해하는 데 도움을 줌. 주요 요약 통계량은 다음과 같다.

- **평균 (Mean):** 데이터의 중심 경향을 나타내는 값으로, 데이터의 모든 값을 더한 후 개수로 나눈 값이다.
- **중앙값 (Median):** 데이터의 중앙에 위치한 값으로, 데이터의 분포를 이해하는 데 유용하다.
- **최빈값 (Mode):** 데이터에서 가장 자주 나타나는 값이다.
- **분산 (Variance):** 데이터가 평균에서 얼마나 떨어져 있는지를 나타내는 값으로, 데이터의 흩어짐 정도를 파악할 수 있다.
- **표준편차 (Standard Deviation):** 분산의 제곱근으로, 데이터의 변동성을 나타내는 값이다.

## 데이터 클렌징(Data Cleansing)

데이터 클렌징은 분석을 위해 데이터를 **정제**하는 과정으로, 결측값 처리, 이상치 탐지, 중복 데이터 제거 등을 포함함. 데이터 클렌징은 데이터의 정확성과 일관성을 높이는 데 중요하다.

- **결측값 처리**: 결측값을 제거하거나 대체하여 분석의 정확성을 높일 수 있다. 결측값을 대체하는 방법으로는 평균, 중앙값, 최빈값 등을 사용할 수 있다.
- **이상치 탐지**: 데이터에서 정상 범위를 벗어난 값을 식별하고 처리하여 분석의 정확성을 높일 수 있다. 이상치를 제거하거나 다른 값으로 대체할 수 있다.
- **중복 데이터 제거**: 동일한 데이터가 중복되어 있는 경우 이를 제거하여 데이터의 일관성을 유지할 수 있다.

## 데이터 변환

데이터 변환은 분석을 위해 데이터를 변형하는 과정으로, 스케일링, 로그 변환, 원-핫 인코딩 등이 포함됨. 이를 통해 데이터의 특성을 변환하여 분석을 용이하게 할 수 있다.

- **스케일링 (Scaling)**: 데이터의 범위를 조정하여 모델의 성능을 향상시킬 수 있다. 주로 Min-Max 스케일링과 표준화(정규화)를 사용한다.
- **로그 변환 (Log Transformation)**: 데이터의 분포를 정규 분포에 가깝게 만들기 위해 로그 변환을 사용할 수 있다. 이는 특히 분포가 한쪽으로 치우쳐 있을 때 유용하다.
- **원-핫 인코딩 (One-Hot Encoding)**: 범주형 데이터를 이진 변수로 변환하여 분석을 용이하게 할 수 있다. 이는 주로 머신러닝 모델에 범주형 데이터를 입력할 때 사용한다.

## 데이터 분석의 목적

EDA의 목적은 데이터의 특성을 이해하고, 데이터의 구조와 관계를 파악하며, 추가 분석을 위한 기초를 마련하는 데 있음. 이를 통해 데이터의 질을 평가하고, 이상치를 식별하며, 가설을 수립할 수 있다. EDA는 데이터 분석의 첫 단계로, 데이터에 대한 깊은 이해를 바탕으로 효과적인 분석을 수행할 수 있다.

## EDA의 중요성

EDA는 데이터 분석 과정에서 매우 중요한 단계로, 데이터의 질을 평가하고 분석 방향을 설정하는 데 도움을 줌. 이를 통해 데이터의 특성을 이해하고, 추가 분석을 위한 기초를 마련할 수 있다. EDA를 통해 데이터의 패턴을 발견하고, 가설을 수립하며, 데이터의 구조를 파악할 수 있다.


이와 같이 탐색적 데이터 분석(EDA)은 데이터의 특성을 이해하고 분석 방향을 설정하는 데 중요한 역할을 함. 다양한 시각화 기법과 요약 통계량을 통해 데이터를 이해하고, 데이터 클렌징과 변환을 통해 분석의 정확성을 높일 수 있다. 이를 통해 효과적인 데이터 분석을 수행할 수 있다.

## 4. ChatGPT로 데이터 탐색 실습

## 4. ChatGPT로 데이터 탐색 실습

### WHO 국가 복지 데이터셋 사용

- 데이터셋 로드 및 확인: 데이터셋을 불러오고 기본 정보를 확인.



## 4. ChatGPT로 데이터 탐색 실습

- 데이터셋 소개: WHO 국가 복지 데이터셋의 내용과 구조.

WHO First9cols

|   | Country     | CountryID | Continent | Adolescent fertility |
|---|-------------|-----------|-----------|----------------------|
| 1 | Afghanistan | 1         | 1         | 151                  |
| 2 | Albania     | 2         | 2         | 27                   |
| 3 | Algeria     | 3         | 3         | 6                    |
| 4 | Andorra     | 4         | 2         |                      |
| 5 | Angola      | 5         | 3         | 146                  |
| 6 | Antigua and | 6         | 4         |                      |

이 데이터셋에 대한정보를 간단히 알려줘(설명은 한글로)

- 이 데이터셋은 총 202개의 행과 9개의 열로 구성되어 있으며, 일부 열에는 결측치가 존재한다. 주요 지표로는 청소년 출산율, 성인 문해율, 1인당 국민 총소득, 초등학교 입학율, 총 인구 등이 포함된다

## 4. ChatGPT로 데이터 탐색 실습

### • 데이터셋 소개: WHO 국가 복지 데이터셋의 내용과 구조.

- **Country:** 국가 이름
- **CountryID:** 국가 식별자
- **Continent:** 대륙 코드
- **Adolescent fertility rate (%)**: 청소년 출산율 (백분율)
- **Adult literacy rate (%)**: 성인 문해율 (백분율)
- **Gross national income per capita (PPP international \$)**: 1인당 국민 총소득 (PPP 국제 달러 기준)
- **Net primary school enrolment ratio female (%)**: 여자 초등학교 순 입학율 (백분율)
- **Net primary school enrolment ratio male (%)**: 남자 초등학교 순 입학율 (백분율)
- **Population (in thousands) total**: 총 인구 (천 명 단위)

### WHO 국가 복지 데이터셋 사용

### 기초 통계값 산출 실습

기초 통계값을 알려줘

- **평균 계산:** 데이터셋의 특정 변수에 대한 평균값 계산.
- **분산 계산:** 데이터셋의 특정 변수에 대한 분산값 계산.
- **표준편차 계산:** 데이터셋의 특정 변수에 대한 표준편차 계산.

## 4. ChatGPT로 데이터 탐색 실습

### WHO 국가 복지 데이터셋 사용

### 기초 통계값 산출 실습

기초 통계값을 알려줘

| Basic Statistics Of WHO Dataset |        |             |           |
|---------------------------------|--------|-------------|-----------|
|                                 |        | Country     | CountryID |
| 1                               | count  | 202         | 202.0     |
| 2                               | unique | 202         |           |
| 3                               | top    | Afghanistan |           |
| 4                               | freq   | 1           |           |
| 5                               | mean   |             | 101.5     |

## 4. ChatGPT로 데이터 탐색 실습

데이터셋의 기초 통계값은 다음과 같습니다:

- **Country:** 202개의 고유 국가명
- **CountryID:** 최소 1, 최대 202, 평균 101.5
- **Continent:** 최소 1, 최대 7, 평균 3.579
- **Adolescent fertility rate (%)**: 최소 0, 최대 199, 평균 59.46
- **Adult literacy rate (%)**: 최소 23.6, 최대 99.8, 평균 78.87
- **Gross national income per capita (PPP international \$)**: 최소 260, 최대 60870, 평균 11250.11
- **Net primary school enrolment ratio female (%)**: 최소 6, 최대 100, 평균 84.03
- **Net primary school enrolment ratio male (%)**: 최소 11, 최대 100, 평균 85.70
- **Population (in thousands) total**: 최소 2, 최대 1,328,474, 평균 34,099.64



#### 4. ChatGPT로 데이터 탐색 실습

통계 요약(표를 다운로드 후 엑셀로 열어본다)

|        | Country     | CountryID | Continent | Adolescer | Adult liter | Gross nati | Net prima | Net prima | Population (in thousands) total |         |  |
|--------|-------------|-----------|-----------|-----------|-------------|------------|-----------|-----------|---------------------------------|---------|--|
| count  | 202         | 202       | 202       | 177       | 131         | 178        | 179       | 179       | 189                             |         |  |
| unique | 202         |           |           |           |             |            |           |           |                                 |         |  |
| top    | Afghanistan |           |           |           |             |            |           |           |                                 |         |  |
| freq   | 1           |           |           |           |             |            |           |           |                                 |         |  |
| mean   |             | 101.5     | 3.5792079 | 59.457627 | 78.871755   | 11250.112  | 84.033519 | 85.698324 | 34099.64021                     | 1164021 |  |
| std    |             | 58.456536 | 1.8082627 | 49.10529  | 20.415760   | 12586.753  | 17.788046 | 15.451211 | 131837.70867                    | 7703325 |  |
| min    |             | 1         | 1         | 0         | 23.6        | 260        | 6         | 11        | 2                               |         |  |
| 25%    |             | 51.25     | 2         | 19        | 68.4        | 2112.5     | 79        | 79.5      | 1328                            |         |  |
| 50%    |             | 101.5     | 3         | 46        | 86.5        | 6175       | 90        | 90        | 6640                            |         |  |
| 75%    |             | 151.75    | 5         | 91        | 95.300000   | 14502.5    | 96        | 96        | 20971                           |         |  |
| max    |             | 202       | 7         | 199       | 99.8        | 60870      | 100       | 100       | 1328474                         |         |  |

## 4. ChatGPT로 데이터 탐색 실습

성인 문해율 가장 낮은 나라는?



성인 문해율이 가장 낮은 나라는 부르키나파소(Burkina Faso)이며, 성인 문해율은 23.6%입니다. [\[↗\]](#)



성인 문해율 가장 높은 나라는?



성인 문해율이 가장 높은 나라는 쿠바(Cuba)이며, 성인 문해율은 99.8%입니다. [\[↗\]](#)



감사합니다